

דו"ח חלק 1 - בניית סט נתונים לסרטים

במסגרת העבודה נבנה סט נתונים של סרטים המבוסס על מידע מתוך IMDb, Wikipedia ו-OMDb API. בתהליך בניית הדאטה בוצעו מספר החלטות סינון, עיבוד והשלמת נתונים על מנת לשפר את איכות ואמינות המידע:

1. נבחרו רק רשומות מסוג movie מתוך טבלת title.basics של IMDb.
2. נבחרו סרטים שאורך הסרט שלהם בין 60 ל-300 דקות.
3. נבחרו רק סרטים ששנת היציאה שלהם קטנה או שווה ל-2024.
4. נבחרו רק סרטים ששםם מתחיל באותיות TJ-TZ.
5. הנתונים מטבלאות IMDb שולבו באמצעות המזהה הייחודי tconst.
6. בוצע מיזוג (inner join) עם טבלת title.ratings, כך שנשמרו רק סרטים שקיים עבורם דירוג ב-IMDb.
7. בוצע מיזוג (left join) עם טבלת title.principals, כך שכל הסרטים נשמרו גם אם לא קיים עבורם מידע על שחקנים.
8. נבנתה עמודה של חמשת השחקנים הראשיים (lead_actors_ids) באמצעות טבלת title.principals על פי סדר ההופעה (ordering) של השחקנים עבור כל סרט.
9. עמודת genres הומרה לפורמט של List of Strings, בהתאם למבנה הנתונים המקורי של IMDb כך שכל סרט נשמר כרשימת ז'אנרים ולא כמחרוזת טקסט אחת.
10. לפני תהליך ה-Web Scraping הסרטים מוינו לפי מספר ההצבעות (numVotes), כך שהסרטים הפופולריים יותר יעובדו ראשונים, מאחר שלרוב קיימים עבורם עמודי Wikipedia מלאים ומפורטים יותר.
11. עבור כל סרט נאספו נתונים נוספים מ-Wikipedia באמצעות Web Scraping עם הספריית requests ו-BeautifulSoup. הנתונים שנאספו הם: שפת הסרט (Language), מדינת ההפקה (Country), תקציב הסרט (Budget) והכנסות הסרט (BoxOffice).
12. תהליך החיפוש ב-Wikipedia כלל מספר שאילתות אפשריות המבוססות על שם הסרט ושנת היציאה, במטרה להגדיל את הסיכוי לאיתור עמוד הסרט הנכון.
13. במהלך תהליך החיפוש בוצע טיפול בתווים מיוחדים ובשמות סרטים מורכבים (כגון & ו-ותווים נוספים) באמצעות קידוד כתובות (URL Encoding), על מנת למנוע שגיאות בחיפוש ולאפשר גישה תקינה לעמודי Wikipedia המתאימים.
14. בוצע טיפול בדפי פירושונים (Disambiguation Pages) של Wikipedia, כאשר זוהה דף פירושונים, המערכת חיפשה והפנתה באופן אוטומטי לעמוד הסרט המתאים לפי שם הסרט ושנת היציאה.
15. לצורך שיפור איכות הנתונים, בוצע זיהוי של עמודי סרטים ב-Wikipedia על בסיס מאפיינים אופייניים של Infobox של סרטים, כגון:
- Directed by, Produced by, Starring, Release date, Running time, Budget, Box office
16. תקציר עלילת הסרט (plot) נאסף באמצעות OMDb API ולא באמצעות Wikipedia, מאחר שמדובר בשדה מובנה ואחיד יותר, המפחית טעויות בזיהוי תוכן שאינו שייך לסרט המבוקש.

17. הגישה ל - OMDb API בוצעה באמצעות המזהה הייחודי tconst (IMDb ID) על מנת להבטיח התאמה מדויקת בין הסרטים ב - IMDb לבין הנתונים שהוחזרו מה-API .
18. במהלך תהליך חילוץ הנתונים מ - Wikipedia נלקחו בחשבון גם וריאציות שונות של שמות השדות ב- Infobox, לדוגמה שימוש בצורות יחיד ורבים כגון Language ו-Languages, וכן Countries ו-Country על מנת לשפר את כמות ואיכות הנתונים שנאספו מעמודי הסרטים השונים.

תיאור השדות שכולל סט הנתונים, הטיפוסים והמקור של כל נתון ונתון

שם העמודה	תיאור	טיפוס	מקור
tconst	מזהה ייחודי של הסרט	String	IMDb
primaryTitle	שם הסרט	String	IMDb
startYear	שנת יציאה	Integer	IMDb
runtimeMinutes	אורך הסרט בדקות	Integer	IMDb
genres	רשימת ז'אנרים	List of Strings	IMDb
averageRating	דירוג ממוצע ב-IMDb	Float	IMDb
numVotes	מספר מדרגים	Integer	IMDb
lead_actors_ids	רשימת מזהי השחקנים הראשיים	List of Strings	IMDb
Language	שפת הסרט	String	Wikipedia
Country	מדינת הפקה	String	Wikipedia
budget	תקציב הסרט במיליוני דולרים	Float	Wikipedia
BoxOffice	הכנסות הסרט במיליוני דולרים	Float	Wikipedia
plot	תקציר הסרט	String	OMDb

מספר הסרטים שנאספו

לאחר תהליך הסינון והאיסוף נאספו : 5000 סרטים .

ניתוח ערכים חסרים

שם העמודה	מספר ערכים חסרים	אחוז ערכים חסרים
tconst	0	0.00%
primaryTitle	0	0.00%
startYear	0	0.00%
genres	0	0.00%
lead_actors_ids	486	9.72%
runtimeMinutes	0	0.00%
averageRating	0	0.00%
Language	1196	23.92%
Country	1183	23.66%
numVotes	0	0.00%
budget	3342	66.84%
BoxOffice	3083	61.66%
plot	520	10.40%

במסגרת בדיקת איכות הנתונים, בוצע ניתוח של מספר ואחוז הערכים החסרים בכל אחת מעמודות סט הנתונים.

נמצא כי בעמודות המרכזיות שנלקחו מ-IMDb לא קיימים ערכים חסרים, מאחר שהסרטים סוננו ונשמרו רק לאחר מיזוג תקין של טבלאות IMDb הרלוונטיות.

בעמודת lead_actors_ids נמצאו ערכים חסרים מכיוון שלחלק מהסרטים לא הופיע מידע על שחקנים בטבלת title.principals.

בעמודת plot שנאספה באמצעות OMDb API נמצאו ערכים חסרים, מאחר שלא לכל הסרטים קיים תקציר עלילה זמין במאגר הנתונים של ה-API.

בעמודות שנאספו מ-Wikipedia נמצאו שיעורי חוסר גבוהים יותר, בעיקר בעמודות budget ו-BoxOffice מצב זה נובע מכך שלא לכל הסרטים קיימים עמודי Wikipedia מלאים, ולעיתים מידע על תקציב והכנסות כלל אינו מופיע ב-infobox של הסרט.

בנוסף, בחלק מהסרטים לא הופיע מידע על שפת הסרט או מדינת ההפקה, ולכן התקבלו ערכים חסרים גם בעמודות Language ו-Country.

מספר קבוצה 22, שמות המגישות :

זוהר קולפ : 322435918

רוני פחימה : 212009260